

线性判别

Linear Discriminant

电子科技大学

信息与通信工程学院



信息与通信工程学院

School of Information and Communication Engineering

主要内容

- 线性判别分类(Linear Discriminants for Classification)
- 分类举例
- 线性判别函数
 - 两类问题
 - 多类问题
- 支持矢量机(Support Vector Machine)
- Fisher线性判别
- 自适应增强AdaBoost(Adaptive Boosting)



- 线性判别分类(Linear Discriminants for Classification)
- 分类举例
- 线性判别函数
 - 两类问题
 - 多类问题
- Fisher线性判别
- 支持矢量机(Support Vector Machine)
- 自适应增强AdaBoost(Adaptive Boosting)

线性判别函数


- ▶ 最简单的判别函数形式：输入变量 \mathbf{x} 的线性组合，系数即为模型参数。**linear combination**

$$y = w_1 x_1 + \dots + w_D x_D + b = \mathbf{w}^T \mathbf{x} + b$$

- ▶ 通过输入变量的固定非线性函数变换后进行线性组合，产生广义线性判别。**generalized linear discriminants**.

$$y = \mathbf{w}^T \phi(\mathbf{x}) + b$$

线性判别函数



$$y(x) = \mathbf{w}^T \mathbf{x} + w_0$$



主要内容

- 线性判别分类(Linear Discriminants for Classification)
- 分类举例
- 线性判别函数
 - 两类问题
 - 多类问题
- Fisher线性判别
- 支持向量机(Support Vector Machine)
- 自适应增强AdaBoost(Adaptive Boosting)



线性判别函数

◆ 两类情况：

▶ 判别函数可以表示为 x 的线性函数：

$$y(x) = \mathbf{w}^T \mathbf{x} + b$$

这里 D -维向量 \mathbf{w} 表示为权向量 (weight vector)，参数 b 为偏差 (or 有时也称 “ $-b$ ” as a **bias**).

▶ 几何解释

- ◆ 在 D 维 \mathbf{x} 空间中，判别边界 $y(\mathbf{x}) = 0$ 对应一个 $(D - 1)$ 维超平面(hyperplane).
- ◆ 权向量 \mathbf{w} 为超平面内任意向量的法线。
- ◆ 偏差 b 确定了超平面在 \mathbf{x} 空间的位置。



线性判别函数

◆ 多类情况:

▶ K类: C_1, C_2, \dots, C_K

▶ 三种情形:

▶ 对每一类都采用两类判别

$\Rightarrow x$ belongs to class C_1 or not?

▶ 对每两类采用两类判别


$\Rightarrow x$ belongs to class C_i or C_j ?

▶ Case 2的特例

线性判别函数

◆ 第一种情况举例：

- ▶ 右图所示，每一类别可用单个判别边界与其它类别相分开。
- ▶ 如果一模式 x 属于 C_1 ，则由图可清楚看出：这时 $g_1(x) > 0$ 而 $g_2(x) < 0$ ， $g_3(x) < 0$ 。 C_1 类与其它类之间的边界由 $g_1(x) = 0$ 确定



❖ 例：已知三类 C_1, C_2, C_3 的判别函数分别为：


$$\begin{cases} g_1(\mathbf{x}) = -x_1 + x_2 \\ g_2(\mathbf{x}) = x_1 + x_2 - 5 \\ g_3(\mathbf{x}) = -x_2 + 1 \end{cases}$$

❖ 因此三个判别边界为：

$$\begin{cases} g_1(\mathbf{x}) = -x_1 + x_2 = 0 \\ g_2(\mathbf{x}) = x_1 + x_2 - 5 = 0 \\ g_3(\mathbf{x}) = -x_2 + 1 = 0 \end{cases}$$

线性判别函数

❖对于任一模式 x 如果它的 $g_1(x) > 0$, $g_2(x) < 0$,

$$g_3(\mathbf{x}) \underset{x_2}{<} 0$$


◆如果某个 X 使二个以上的判别函数 $g_i(x) > 0$ 。
则此模式 X 就无法作出确切的判决。如图中
IR1,IR3, IR4区域。

◆ 另一种情况是IR2区域，判别函数都为负值。IR1，IR2，IR3，IR4。都为不确定区域。

$$\begin{cases} g_1(\mathbf{x}) = -x_1 + x_2 \\ g_2(\mathbf{x}) = x_1 + x_2 - 5 \\ g_3(\mathbf{x}) = -x_2 + 1 \end{cases}$$

线性判别函数

❖问：当 $\mathbf{x} = (x_1, x_2)^T = (6, 5)^T$ 时属于哪一类？

代入判别函数方程组：

$$\begin{cases} g_1(\mathbf{x}) = -x_1 + x_2 \\ g_2(\mathbf{x}) = x_1 + x_2 - 5 \\ g_3(\mathbf{x}) = -x_2 + 1 \end{cases}$$

得： $g_1(\mathbf{x}) = -1, g_2(\mathbf{x}) = 6, g_3(\mathbf{x}) = -4.$

❖结论： $g_1(\mathbf{x}) < 0, g_2(\mathbf{x}) > 0, g_3(\mathbf{x}) < 0$ 所以它属于 C_2 类

线性判别函数

◆第二种情况举例

➤ 每个模式类和其它模式类间可分别用判别平面分开(M 种模式)。

❖ 这样有 $M(M - 1)/2$ 个判别平面。


❖ 对于两类问题, $M = 2$, 则有一个判别平面。

❖ 同理, 三类问题则有三个判别平面。

❖ 判别函数: $g_{ij}(x) = \omega_{ij}^T x + b_{ij}$

❖ 判别边界: $g_{ij}(x) = 0$

❖ 判别条件: $g_{ij}(x) \begin{cases} > 0 \rightarrow \text{当 } x \in \omega_i \\ < 0 \rightarrow \text{当 } x \in \omega_j \end{cases} \quad i \neq j$




线性判别函数

❖ 判别函数性质: $g_{ij}(\mathbf{x}) = -g_{ji}(\mathbf{x})$


❖ 假设判别函数为:
$$\begin{cases} g_{12}(\mathbf{x}) = -x_1 - x_2 + 5 \\ g_{13}(\mathbf{x}) = -x_1 + 3 \\ g_{23}(\mathbf{x}) = -x_1 + x_2 \end{cases}$$

❖ 判别边界为:


$$\begin{cases} g_{12}(\mathbf{x}) = -x_1 - x_2 + 5 = 0 \\ g_{13}(\mathbf{x}) = -x_1 + 3 = 0 \\ g_{23}(\mathbf{x}) = -x_1 + x_2 = 0 \end{cases}$$




ω_i/ω_j 两分法例题图示



ω_i/ω_j 两分法例题图示



ω_i/ω_j 两分法例题图示



ω_i/ω_j 两分法例题图示

线性判别函数

◆ 结论：判别区间增大，不确定区间减小，比第一种情况小的多.

❖ 问：未知模式 $\mathbf{x} = (x_1, x_2)^T = (4, 3)^T$ 属于哪一类？

❖ 代入判别函数可得：

$$g_{12}(\mathbf{x}) = -2, g_{13}(\mathbf{x}) = -1, g_{23}(\mathbf{x}) = -1$$

$$\begin{cases} g_{12}(\mathbf{x}) = -x_1 - x_2 + 5 = 0 \\ g_{13}(\mathbf{x}) = -x_1 + 3 = 0 \\ g_{23}(\mathbf{x}) = -x_1 + x_2 = 0 \end{cases}$$

❖ 把下标对换可得：

$$g_{21}(\mathbf{x}) = 2, g_{31}(\mathbf{x}) = 1, g_{32}(\mathbf{x}) = 1$$

❖ 因为 $g_{3j}(\mathbf{x}) > 0$

❖ 结论：所以 \mathbf{x} 属于 C_3 类

◆第三种情况举例

❖ 每类都有一个判别函数,存在 M 个判别函数

❖ 判别函数: $g_K(\mathbf{x}) = \boldsymbol{\omega}_K^T \mathbf{x} + b_K \quad K = 1, 2, \dots, M$

❖ 判别规则: $g_i(\mathbf{x}) = \boldsymbol{\omega}_K^T \mathbf{x} + b_K \begin{cases} \mathbf{x} \in \omega_i & g_i(\mathbf{x}) > g_j(\mathbf{x}), \forall j \& j \neq i \\ uncertain & otherwise \end{cases}$

❖ 判别边界: $g_i(\mathbf{x}) = g_j(\mathbf{x})$ 或 $g_i(\mathbf{x}) - g_j(\mathbf{x}) = 0$

❖ 就是说, 要判别模式 \mathbf{x} 属于哪一类, 先把 \mathbf{x} 代入 M 个判别函数中, 判别函数最大的那个类别就是 \mathbf{x} 所属类别。类与类之间的边界可由 $g_i(\mathbf{x}) = g_j(\mathbf{x})$ 或 $g_i(\mathbf{x}) - g_j(\mathbf{x}) = 0$ 来确定。

❖ 无不确定区间


线性判别函数

- ❖ 右图所示是 $K=3$ 的例子。对于 C_1 类模式,
- ❖ 必然满足 $g_1(\mathbf{x}) > g_2(\mathbf{x})$ 和 $g_1(\mathbf{x}) > g_3(\mathbf{x})$ 。
- ❖ 假设判别函数为:

$$\begin{cases} g_1(\mathbf{x}) = -x_1 + x_2 \\ g_2(\mathbf{x}) = x_1 + x_2 - 1 \\ g_3(\mathbf{x}) = -x_2 \end{cases}$$

- ❖ 则判别边界为:

$$\begin{cases} g_1(\mathbf{x}) - g_2(\mathbf{x}) = -2x_1 + 1 = 0 \\ g_1(\mathbf{x}) - g_3(\mathbf{x}) = -x_1 + 2x_2 = 0 \\ g_2(\mathbf{x}) - g_3(\mathbf{x}) = x_1 + 2x_2 - 1 = 0 \end{cases}$$



问：假设未知模式 $\mathbf{x} = (x_1, x_2)^T = (1, 1)^T$,
则 \mathbf{x} 属于那一类？


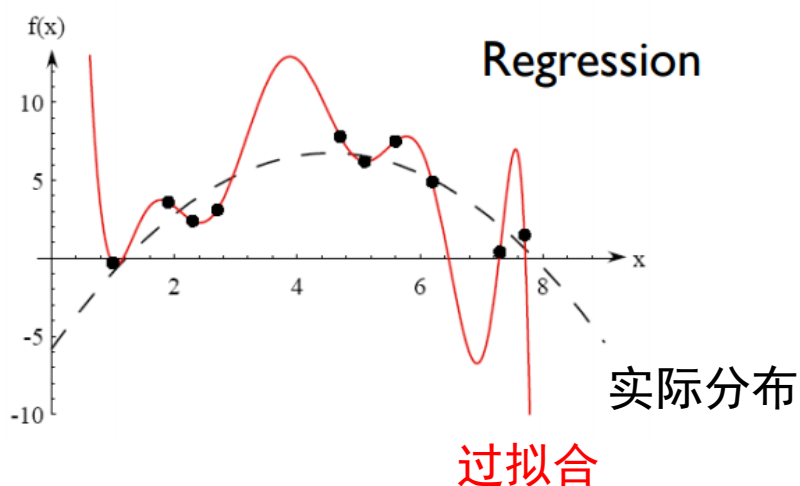
主要内容

- 线性判别分类(Linear Discriminants for Classification)
- 分类举例
- 线性判别函数
 - 两类问题
 - 多类问题
- Fisher线性判别
- 支持矢量机(Support Vector Machine)
- 自适应增强AdaBoost(Adaptive Boosting)




挑战：高维空间上的分类界面计算复杂，样本稀疏，
过拟合风险高

思路：高维空间**降维**到低维空间实现简单高效判别



Fisher线性判别



方法：求取线性投影 $y = w^T x$ ，将高维表示 x 降维到低维表示 y ，保证 y **利于分类**。



二维模式向一维空间投影示意图

Fisher线性判别

- Fisher线性判别



Fisher判别法是1936年提出来的，该方法的主要思想是通过将多维数据投影到某个方向上，投影的原则是将总体与总体之间尽可能的分开，然后再选择合适的判别规则，将新的样本进行分类判别。

(1) 求解Fisher准则函数

设给定 n 维训练样本 $x_1 \dots x_N$ ，其中有 N_1 和 $N_2 = N - N_1$ 个样本分属 C_1 类和 C_2 类。

待求 w

$$y = \mathbf{w}^T \mathbf{x}.$$

$$J(\mathbf{w}) = \frac{(m_2 - m_1)^2}{s_{W_1} + s_{W_2}}$$

s_{W_k} 记为类内离差度。

类别中心：

$$\mathbf{m}_1 = \frac{1}{N_1} \sum_{\mathbf{x}_n \in \mathcal{C}_1} \mathbf{x}_n$$
$$\mathbf{m}_2 = \frac{1}{N_2} \sum_{\mathbf{x}_n \in \mathcal{C}_2} \mathbf{x}_n$$

变换后各个模式在投影方向 \mathbf{w} 上的均值可以表示为：

$$m_1 = \frac{1}{N_1} \sum_{\mathbf{x}_n \in \mathcal{C}_1} \mathbf{w}^T \mathbf{x}_n = \mathbf{w}^T \mathbf{m}_1$$
$$m_2 = \frac{1}{N_2} \sum_{\mathbf{x}_n \in \mathcal{C}_2} \mathbf{w}^T \mathbf{x}_n = \mathbf{w}^T \mathbf{m}_2$$

类内散度：

$$S_W = \sum_{x_n \in C_1} (\mathbf{w}^T \mathbf{x}_n - \mathbf{w}^T \mathbf{m}_1)^2 + \sum_{x_n \in C_2} (\mathbf{w}^T \mathbf{x}_n - \mathbf{w}^T \mathbf{m}_2)^2 = \mathbf{w}^T \mathbf{S}_W \mathbf{w}$$

类内散度矩阵：

$$\mathbf{S}_W = \sum_{x_n \in C_1} (\mathbf{x}_n - \mathbf{m}_1) (\mathbf{x}_n - \mathbf{m}_1)^T + \sum_{x_n \in C_2} (\mathbf{x}_n - \mathbf{m}_2) (\mathbf{x}_n - \mathbf{m}_2)^T$$

类间散度：

$$\begin{aligned} s_B &= (\mathbf{m}_2 - \mathbf{m}_1)^2 \\ &= (\mathbf{w}^T \mathbf{m}_2 - \mathbf{w}^T \mathbf{m}_1)^2 = \mathbf{w}^T \mathbf{S}_B \mathbf{w} \end{aligned}$$

类间散度矩阵：

$$\mathbf{S}_B = (\mathbf{m}_2 - \mathbf{m}_1)(\mathbf{m}_2 - \mathbf{m}_1)^T$$

根据Fisher 准则的定义，期望类内散度 s_W 越小，类间散度 s_B 越大越好，根据以上准则定义目标函数：

$$J(\mathbf{w}) = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}}$$

求解 $J(\mathbf{w}) = \frac{\mathbf{w}^T \mathbf{S}_B \mathbf{w}}{\mathbf{w}^T \mathbf{S}_W \mathbf{w}}$ 转化为优化问题:

$$\max_{\mathbf{w}} \mathbf{w}^T \mathbf{S}_B \mathbf{w}$$

$$s. t. \mathbf{w}^T \mathbf{S}_W \mathbf{w} = c \neq 0$$

s. t. 表示优化问题中需要满足约束的条件 (subject to的缩写)

拉格朗日乘子法：

假设需要求极值的目标函数 (objective function) 为 $f(x, y)$ ，限制条件为 $\varphi(x, y) = M$

设 $g(x, y) = M - \varphi(x, y)$

定义一个新函数

$$F(x, y, \lambda) = f(x, y) + \lambda g(x, y)$$

则用偏导数方法列出方程：

$$\partial F / \partial x = 0$$

$$\partial F / \partial y = 0$$

$$\partial F / \partial \lambda = 0$$

求出 x, y, λ 的值，代入即可得到目标函数的极值

扩展为多个变量的式子为：

$$F(x_1, x_2, \dots, \lambda) = f(x_1, x_2, \dots) + \lambda g(x_1, x_2, \dots)$$

则求极值点的方程为：

$$\partial F / \partial x_i = 0 \quad (x_i \text{ 即为 } x_1, x_2, \dots \text{ 等自变量})$$

$$\partial F / \partial \lambda = g(x_1, x_2, \dots) = 0$$

通过引入拉格朗日乘子转化为以下拉格朗日无约束极值问题：

$$L(\mathbf{w}, \lambda) = \mathbf{w}^T \mathbf{S}_B \mathbf{w} - \lambda(\mathbf{w}^T \mathbf{S}_W \mathbf{w} - c)$$

令导数

$$\frac{\partial L(\mathbf{w}, \lambda)}{\partial \mathbf{w}} = 0$$

可得：

$$\mathbf{S}_B \mathbf{w} - \lambda \mathbf{S}_W \mathbf{w} = \mathbf{0}$$

可得：

$$S_B \mathbf{w} = \lambda S_W \mathbf{w}$$

假定 S_W 为非奇异，则：

$$S_W^{-1} S_B \mathbf{w} = \lambda \mathbf{w}$$

即最佳投影方向为 $S_W^{-1} S_B$ 的特征向量。

(3) 求解Fisher判别函数

- 由于变换后的模式是一维的，因此判别界面实际上是各类模式所在轴上的一个点，所以可以根据训练模式确定一个阈值 w_0 ，于是Fisher判别规则为：

$$w^T x \begin{matrix} > \\ < \end{matrix} w_0 \quad x \in \begin{cases} C_1 \\ C_2 \end{cases}$$

- 判别阈值可取两个类心在 w 方向上轴的投影连线的中点作为阈值，即：

$$w_0 = \frac{m_1 + m_2}{2}$$



Fisher线性判别

判别规则为：

$$\mathbf{w}^T \mathbf{x}_n \begin{matrix} > \\ < \end{matrix} w_0, \quad \mathbf{x}_n \in \begin{cases} \mathcal{C}_1 \\ \mathcal{C}_2 \end{cases}$$

等价于：

$$g(\mathbf{x}_n) = \mathbf{w}^T \mathbf{x}_n - w_0 \begin{matrix} > \\ < \end{matrix} 0, \quad \mathbf{x}_n \in \begin{cases} \mathcal{C}_1 \\ \mathcal{C}_2 \end{cases}$$



1. 计算类内散度矩阵:

$$\begin{aligned} \mathbf{S}_W = & \sum_{x_n \in C_1} (x_n - m_1)(x_n - m_1)^T \\ & + \sum_{x_i \in C_2} (x_i - m_2)(x_i - m_2)^T \end{aligned}$$

2. 计算类间散度矩阵:

$$\mathbf{S}_B = (m_2 - m_1)(m_2 - m_1)^T$$


3. 求解特征值:

$$\mathbf{S}_W^{-1} \mathbf{S}_B \mathbf{w} = \lambda \mathbf{w}$$

Fisher线性判别示例：

给定如下两类样本，

$$\mathbf{X}_1 = \begin{bmatrix} 1 & 2 \\ 2 & 3 \\ 3 & 3 \\ 4 & 5 \\ 5 & 5 \end{bmatrix}^T \quad \mathbf{X}_2 = \begin{bmatrix} 1 & 0 \\ 2 & 1 \\ 3 & 1 \\ 3 & 2 \\ 5 & 3 \\ 6 & 5 \end{bmatrix}^T$$



(1) 首先计算两类样本均值：

$$\mathbf{m}_1 = [3 \quad 3.6]^T \quad \mathbf{m}_2 = [3.3 \quad 2]^T$$

(2) 计算两类各自的类内离差阵：

$$\mathbf{S}_{W_1} = \sum_n (\mathbf{x}_n - \mathbf{m}_1)(\mathbf{x}_n - \mathbf{m}_1)^T = \begin{bmatrix} 10 & 8 \\ 8 & 7.2 \end{bmatrix}$$

$$\mathbf{S}_{W_2} = \sum_n (\mathbf{x}_n - \mathbf{m}_2)(\mathbf{x}_n - \mathbf{m}_2)^T = \begin{bmatrix} 17.3 & 16 \\ 16 & 16 \end{bmatrix}$$

(3) 计算类内总离差阵：

$$\mathbf{S}_W = \mathbf{S}_{W_1} + \mathbf{S}_{W_2} = \begin{bmatrix} 27.3 & 24 \\ 24 & 23.2 \end{bmatrix}$$


(4) 计算总离差阵的逆矩阵和投影向量：

$$S_W^{-1} = \begin{bmatrix} 0.40 & -0.42 \\ -0.42 & 0.48 \end{bmatrix}, S_B = \begin{bmatrix} 0.09 & -0.48 \\ -0.48 & 2.56 \end{bmatrix}, \mathbf{w} = \begin{bmatrix} -0.79 \\ 0.89 \end{bmatrix}$$

(5) 计算每类样本的投影：

$$Y_1 = \mathbf{w} \cdot \mathbf{X}_1 = \begin{bmatrix} 0.99 \\ 1.09 \\ 0.30 \\ 1.29 \\ 0.50 \end{bmatrix}^T$$

$$Y_2 = \mathbf{w} \cdot \mathbf{X}_2 = \begin{bmatrix} -0.79 \\ -0.69 \\ -1.48 \\ -0.59 \\ -1.28 \\ -0.29 \end{bmatrix}^T$$



(6) 计算两类判别门限:

$$w_0 = \frac{\mathbf{w}^T \mathbf{m}_1 + \mathbf{w}^T \mathbf{m}_2}{2} = 0.004$$

$$Y_1 = \mathbf{w}^T \mathbf{X}_1 = \begin{bmatrix} 0.99 \\ 1.09 \\ 0.30 \\ 1.29 \\ 0.5 \end{bmatrix}^T > w_0 \quad Y_2 = \mathbf{w}^T \mathbf{X}_1 = \begin{bmatrix} -0.79 \\ -0.69 \\ -1.48 \\ -0.59 \\ -1.28 \\ -0.29 \end{bmatrix}^T < w_0$$

两类样本全部正确划分


课堂练习：

1. 有两类样本：

$$C_1: \{(1,1)^T, (3,1)^T\}$$

$$C_2: \{(1,-2)^T, (3,0)^T\}$$

用Fisher准则进行分类，并分析其分类性能。



答案： (1) 首先计算两类样本均值：

$$\mathbf{m}_1 = [2 \quad 1]^T \quad \mathbf{m}_2 = [2 \quad -1]^T$$

(2) 计算两类各自的类内离差阵：

$$\mathbf{S}_{W_1} = \sum_n (\mathbf{x}_n - \mathbf{m}_1)(\mathbf{x}_n - \mathbf{m}_1)^T = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}$$

$$\mathbf{S}_{W_2} = \sum_n (\mathbf{x}_n - \mathbf{m}_2)(\mathbf{x}_n - \mathbf{m}_2)^T = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}$$

(3) 计算类内总离差阵：

$$\mathbf{S}_W = \mathbf{S}_{W_1} + \mathbf{S}_{W_2} = \begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix}$$


(4) 计算总离差阵的逆矩阵和投影向量：

$$S_W^{-1} = \frac{1}{4} \begin{bmatrix} 2 & -2 \\ -2 & 4 \end{bmatrix}, S_B = \begin{bmatrix} 0 & 0 \\ 0 & 4 \end{bmatrix}, \mathbf{w} = \begin{bmatrix} -1 \\ 2 \end{bmatrix}$$

(5) 计算每类样本的投影：

$$Y_1 = \mathbf{w} \cdot \mathbf{X}_1 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}^T$$

$$Y_2 = \mathbf{w} \cdot \mathbf{X}_2 = \begin{bmatrix} -5 \\ -3 \end{bmatrix}^T$$



(6) 计算两类判别门限：

$$w_0 = \frac{\mathbf{w}^T \mathbf{m}_1 + \mathbf{w}^T \mathbf{m}_2}{2} = -2$$

$$Y_1 = \mathbf{w}^T \boldsymbol{\omega}_1 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}^T > w_0 \quad Y_2 = \mathbf{w}^T \boldsymbol{\omega}_2 = \begin{bmatrix} -5 \\ -3 \end{bmatrix}^T < w_0$$


两类样本全部正确划分

主要内容

- 线性判别分类(Linear Discriminants for Classification)
- 分类举例
- 线性判别函数
 - 两类问题
 - 多类问题
- Fisher线性判别
- 支持矢量机(Support Vector Machine)
- 自适应增强AdaBoost(Adaptive Boosting)




- 哪个超平面更好？




支持向量机


- 如下分类界面的优劣？



A




B




C

支持向量机


- 如何提高分类界面对噪声的鲁棒性？



A



B




C

增大分类界面的缓冲空间 (margin), 是提升其鲁棒性的关键

支持向量机

- 如何度量margin?
- 从回顾线性代数的几何性质开始



1. 超平面的权重向量，与平面上所有向量正交：

证明：设 x_1, x_2 是平面 $w^T x + b$ 上的点，且满足

$$w^T x_1 + b = w^T x_2 + b = 0$$




$$w^T (x_1 - x_2) + b = 0$$

即，向量 w 垂直于该超平面

支持向量机

- 如何度量margin?

➤从回顾线性代数的几何性质开始



当 x_a 在分类界面右侧

2. 超平面外任意一点 x_a , 到该平面的距离为:

$$\frac{|\mathbf{w}^T \mathbf{x}_a + b|}{\|\mathbf{w}\|}$$

证明: 设 r 表示 x 到平面 $\mathbf{w}^T \mathbf{x} + b$ 的垂直距离, 其中 \mathbf{x}_p 是 \mathbf{x}_a 到平面 $\mathbf{w}^T \mathbf{x} + b$ 的正交投影向量, 则

$$\mathbf{x}_a = \mathbf{x}_p + r \cdot \frac{\mathbf{w}}{\|\mathbf{w}\|} \quad \text{且} \quad \mathbf{w}^T \mathbf{x}_p + b = 0$$




$$r = \frac{\mathbf{w}^T \mathbf{x}_a + b}{\|\mathbf{w}\|} \quad \leftarrow \quad \mathbf{w}^T \mathbf{x}_a + b = \mathbf{w}^T \left(\mathbf{x}_p + r \cdot \frac{\mathbf{w}}{\|\mathbf{w}\|} \right) + b = r \cdot \frac{\mathbf{w}^T \mathbf{w}}{\|\mathbf{w}\|} = r \cdot \|\mathbf{w}\|$$

支持向量机

- 如何度量margin?

➤ 从回顾线性代数的几何性质开始



当 x_a 在分类界面左侧

$$x_a = x_p - r \cdot \frac{\mathbf{w}}{\|\mathbf{w}\|} \quad \text{且} \quad \mathbf{w}^T x_p + b = 0$$



$$\mathbf{w}^T x_a + b = \mathbf{w}^T \left(x_p - r \cdot \frac{\mathbf{w}}{\|\mathbf{w}\|} \right) + b = -r \cdot \frac{\mathbf{w}^T \mathbf{w}}{\|\mathbf{w}\|} = -r \cdot \|\mathbf{w}\|$$




$$r = -\frac{\mathbf{w}^T x_a + b}{\|\mathbf{w}\|}$$

综上, 无论 x_a 在任何位置, 其到超平面的垂直距离为 $\frac{|\mathbf{w}^T x_a + b|}{\|\mathbf{w}\|}$


支持向量机

- 特征投影示例

➤ 假设我们采用如下投影函数 $\mathbf{x} = (x_1, x_2)^T, \varphi(\mathbf{x}) = (\sqrt{2}x_1x_2, x_1^2, x_2^2)^T$



$\varphi(\mathbf{x})$
高维投影




投影后特征线性可分，我们可在投影空间上求取线性判别函数

边界 (Margin)

Margin: 决策边界和任意一个样本之间的最小距离。点 \mathbf{x}_n 到决策面的距离为:

$$\frac{t_n y(\mathbf{x}_n)}{\|\mathbf{w}\|} = \frac{t_n (\mathbf{w}^T \phi(\mathbf{x}_n) + b)}{\|\mathbf{w}\|}$$



最大化边界

我们希望优化参数 \mathbf{w} 和 b ，以使Margin最大化。

$$\arg \max_{\mathbf{w}, b} \left\{ \frac{1}{\|\mathbf{w}\|} \min_n \left[t_n \left(\mathbf{w}^T \phi(\mathbf{x}_n) + b \right) \right] \right\}$$

如果进行重新缩放，使得 $\mathbf{w} \rightarrow k\mathbf{w}, b \rightarrow kb$ ；则对于任意一点 \mathbf{x}_n 到决策面的距离 $t_n y(\mathbf{x}_n) / \|\mathbf{w}\|$ 是保持不变的。

我们可以利用这一点来设置距离该决策面最近的点的取值：

$$t_n \left(\mathbf{w}^T \phi(\mathbf{x}_n) + b \right) = 1$$



支持向量 (Support vector)

对于支持向量:

$$t_n (\mathbf{w}^T \phi(\mathbf{x}_n) + b) = 1$$


对于所有点:

$$t_n (\mathbf{w}^T \phi(\mathbf{x}_n) + b) \geq 1, \quad n = 1, \dots, N.$$

我们希望最小化边界:

$$\max_{\mathbf{w}, b} \frac{1}{\|\mathbf{w}\|^2}$$

$$s.t. \quad t_n (\mathbf{w}^T \phi(\mathbf{x}_n) + b) \geq 1$$



等效于最小化 $\|\mathbf{w}\|^2$:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2$$

$$s.t. \quad t_n \left(\mathbf{w}^T \phi(\mathbf{x}_n) + b \right) \geq 1$$

以上是一个具有凸二次目标函数、仅有线性约束的优化问题。
这个优化问题可以用商业QP软件来解决。

拉格朗日对偶 (Lagrange duality)

引入拉格朗日乘子 $a_n \geq 0$ ，每个约束条件都对应一个乘子 a_n 。

$$L(\mathbf{w}, b, \mathbf{a}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{n=1}^N a_n \{t_n(\mathbf{w}^T \phi(\mathbf{x}_n) + b) - 1\}$$

令 $L(\mathbf{w}, b, \mathbf{a})$ 关于 \mathbf{w} 和 b 的偏导数等于零，可获得以下两个条件：

$$\begin{aligned}\mathbf{w} &= \sum_{n=1}^N a_n t_n \phi(\mathbf{x}_n) \\ 0 &= \sum_{n=1}^N a_n t_n.\end{aligned}$$



拉格朗日对偶 (Lagrange duality)

引入拉格朗日乘子 $a_n \geq 0$ ，每个约束条件都对应一个乘子 a_n 。

$$L(\mathbf{w}, b, \mathbf{a}) = \frac{1}{2} \underbrace{\|\mathbf{w}\|^2} - \sum_{n=1}^N \underbrace{a_n \{t_n(\mathbf{w}^T \phi(\mathbf{x}_n) + b) - 1\}}$$

$$\mathbf{w} = \sum_{n=1}^N a_n t_n \phi(\mathbf{x}_n) = 0$$

使用这些条件从 $L(\mathbf{w}, b, \mathbf{a})$ 中消除 \mathbf{w} 和 b ，可得到对偶表示 $\tilde{L}(\mathbf{a})$ ：

$$\sum_{n=1}^N a_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N a_n a_m t_n t_m \underbrace{\phi^T(\mathbf{x}_n) \phi(\mathbf{x}_m)}_{k(\mathbf{x}_n, \mathbf{x}_m)}$$



拉格朗日对偶 (Lagrange duality)

使用核函数 $k(\mathbf{x}, \mathbf{x}) = \phi(\mathbf{x})^T \phi(\mathbf{x})$, 可得到对偶问题:

$$\tilde{L}(\mathbf{a}) = \sum_{n=1}^N a_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N a_n a_m t_n t_m k(\mathbf{x}_n, \mathbf{x}_m)$$

$$a_n \geq 0, \quad n = 1, \dots, N,$$

$$\sum_{n=1}^N a_n t_n = 0.$$

对偶表示是一个二次规划问题。

具有 N 个参数: $\{a_1, \dots, a_N\}$, 从而能够对新的数据点进行分类。

$$y = \mathbf{w}^T \phi(\mathbf{x}) + b = \sum_{n=1}^N a_n t_n \underbrace{\phi(\mathbf{x}_n)^T \phi(\mathbf{x})}_{k(\mathbf{x}, \mathbf{x}_n)} + b$$



这种形式的约束性优化满足*Karush-Kuhn-Tucker* (KKT) 条件，在这种情况下，它要求以下三个性质成立：

$$\begin{aligned}a_n &\geq 0 \\t_n y(\mathbf{x}_n) - 1 &\geq 0 \\a_n \{t_n y(\mathbf{x}_n) - 1\} &= 0.\end{aligned}$$

根据 $a_n \{t_n y(\mathbf{x}_n) - 1\} = 0$ ，可以得到对于任意数据点，有 $a_n = 0$ 或 $t_n y(\mathbf{x}_n) = 1$ 。 $a_n = 0$ 的任何数据点不会出现在目标函数中，其余满足 $t_n y(\mathbf{x}_n) = 1$ 的数据点称为**支持向量**。

$$\tilde{L}(\mathbf{a}) = \sum_{n=1}^N a_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N a_n a_m t_n t_m k(\mathbf{x}_n, \mathbf{x}_m)$$

求解 a 和 b

求解二次规划问题，并找到 a 的值。然后根据 $t_n y(\mathbf{x}_n) = 1$ ，确定任意支持向量的 b 值。

$$t_n \left(\sum_{m \in \mathcal{S}} a_m t_m k(\mathbf{x}_n, \mathbf{x}_m) + b \right) = 1$$

乘 t_n （利用 $t_n^2 = 1$ ）：

$$t_n \left(\sum_{m \in \mathcal{S}} a_m t_m k(\mathbf{x}_n, \mathbf{x}_m) + b \right) = 1$$

然后可以得到：

$$b = \frac{1}{N_{\mathcal{S}}} \sum_{n \in \mathcal{S}} \left(t_n - \sum_{m \in \mathcal{S}} a_m t_m k(\mathbf{x}_n, \mathbf{x}_m) \right)$$



拉格朗日对偶 (Lagrange duality)

使用核函数 $k(\mathbf{x}, \mathbf{x}) = \phi(\mathbf{x})^T \phi(\mathbf{x})$, 可得到对偶问题:

$$\tilde{L}(\mathbf{a}) = \sum_{n=1}^N a_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N a_n a_m t_n t_m k(\mathbf{x}_n, \mathbf{x}_m)$$

$$a_n \geq 0, \quad n = 1, \dots, N,$$

$$\sum_{n=1}^N a_n t_n = 0.$$

乘 t_n (利用 $t_n^2 = 1$) :

$$t_n \left(\sum_{m \in \mathcal{S}} a_m t_m k(\mathbf{x}_n, \mathbf{x}_m) + b \right) = 1$$


然后可以得到:

$$b = \frac{1}{N_{\mathcal{S}}} \sum_{n \in \mathcal{S}} \left(t_n - \sum_{m \in \mathcal{S}} a_m t_m k(\mathbf{x}_n, \mathbf{x}_m) \right)$$



支持向量 (Support vectors)

- 决策边界 (the decision boundary)
- 边界界限 (The margin boundaries)
- 支持向量 (the support vectors)



假设一个核函数：

$$k(\mathbf{x}, \mathbf{x}') = (\mathbf{x}^T \mathbf{x}')^2$$

可将其改写为：

$$\begin{aligned} k(\mathbf{x}, \mathbf{x}') &= \left(\sum_{i=1}^D x_i x'_i \right) \left(\sum_{j=1}^D x_j x'_j \right) \\ &= \sum_{i=1}^D \sum_{j=1}^D x_i x_j x'_i x'_j \\ &= \sum_{i,j=1}^D (x_i x_j) (x'_i x'_j) \end{aligned}$$

$$k(\mathbf{x}, \mathbf{x}') = \phi(\mathbf{x})^T \phi(\mathbf{x}')$$

其中特征映射（对于 $D=3$ ）为：

$$\phi(\mathbf{x}) = \begin{pmatrix} x_1 x_1 \\ x_1 x_2 \\ x_1 x_3 \\ x_2 x_1 \\ x_2 x_2 \\ x_2 x_3 \\ x_3 x_1 \\ x_3 x_2 \\ x_3 x_3 \end{pmatrix}$$

核函数 (Kernels)

- 多项式核函数: $k(\mathbf{x}, \mathbf{x}') = (\mathbf{x}^T \mathbf{x}' + c)^M$


- 高斯核函数: $k(\mathbf{x}, \mathbf{x}') = \exp(-\|\mathbf{x} - \mathbf{x}'\|^2 / 2\sigma^2)$

- Sigmoid核函数: $k(\mathbf{x}, \mathbf{x}') = \tanh(a\mathbf{x}^T \mathbf{x}' + b)$




核函数 (Kernels)


- 不同核函数对不同数据分布表现各异




原始数据分布



线性核分类结果




多项式核分类结果




径向基核分类结果

核函数 (Kernels)


- 不同核函数对不同数据分布表现各异




原始数据分布



线性核分类结果




多项式核分类结果




径向基核分类结果

核函数 (Kernels)


- 不同核函数对不同数据分布表现各异




原始数据分布



线性核分类结果



多项式核分类结果



径向基核分类结果

支持向量机

- 利用LIBSVM工具包实现分类器训练和测试

- 第一步：下载LIBSVM工具包(见如下链接)

工具包链接: <http://ivipc.uestc.edu.cn/>

- 第二步：将解压的工具包放入matlab目录下，如

C: MATLAB\R2014a\toolbox

- 第三步：添加路径至当前工作区，如

```
p='C: MATLAB\R2014a\toolbox\libsvm\matlab';
```

```
addpath(genpath(p));
```

- 第四步：编译工具包

```
mex -setup;
```

```
make;
```



支持向量机

- 利用LIBSVM工具包实现分类器训练和测试
- 第五步：训练和测试

```
[heart_scale_label, heart_scale_inst] = libsvmread('heart_scale'); % 读取数据
```

↑
标签

↑
特征

```
model = svmtrain(heart_scale_label, heart_scale_inst, '-c 1 -g 0.07'); % 训练模型
```

↑
分类模型

↑
参数设置

```
[predict_label, accuracy, dec_values] = svmpredict(heart_scale_label, heart_scale_inst, model); % 测试
```

↑
预测标签

↑
分类精度

↑
决策值

- 作业

- 利用LIBSVM工具包，编写MATLAB程序，对下列a1a性别分类数据集进行SVM分类，对比线性核，多项式核以及径向基核分类的差异。

- 数据集链接：

<http://ivipc.uestc.edu.cn/>

主要内容

- 线性判别分类(Linear Discriminants for Classification)
- 分类举例
- 线性判别函数
 - 两类问题
 - 多类问题
- Fisher线性判别
- 支持矢量机(Support Vector Machine)
- 自适应增强AdaBoost(Adaptive Boosting)



AdaBoost算法

- 挑战：

- 对任意机器学习算法或策略，出错在所难免；
- 一种机器学习算法或策略难以始终实现最优；

- 思路：

- 集成多个机器学习算法或策略的结果，彼此互补，整体提升。



AdaBoost算法

- 如何有效集成多个分类器？
 - 用许多弱分类器 **自适应加权** 构成一个强分类器

$$\begin{aligned} y_1(\mathbf{x}) &\in \{-1, +1\} \\ &\vdots \\ y_M(\mathbf{x}) &\in \{-1, +1\} \end{aligned}$$

$$Y_M(\mathbf{x}) = \text{sign} \left(\sum_{m=1}^M \alpha_m y_m(\mathbf{x}) \right)$$

自适应权重

弱分类器

强分类器

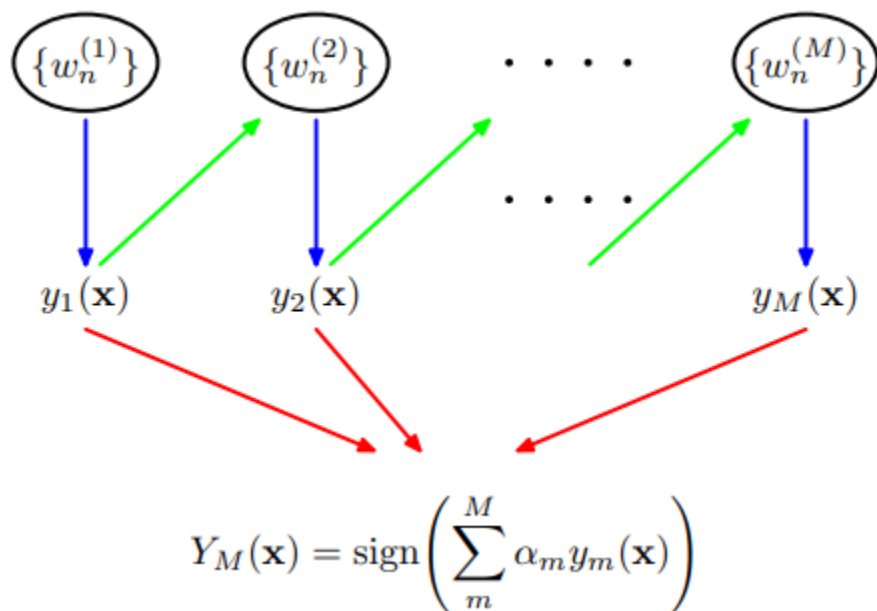
单个弱分类器可能只稍微好于随机分类效果

AdaBoost算法

$$\begin{aligned} y_1(\mathbf{x}) &\in \{-1, +1\} \\ &\vdots \\ y_M(\mathbf{x}) &\in \{-1, +1\} \end{aligned}$$

• 需要解决的问题：

- 如何选择弱分类器？
- 如何为训练样本分配权重？
- 如何为每个弱分类器分配权重？



AdaBoost算法

给定: $(x_1, t_1), \dots, (x_N, t_N)$,

均匀初始化样本权重: $w_n^{(1)} = \frac{1}{N}, n = 1, \dots, N$

For $m = 1, \dots, M$:

- 学习弱分类器 $y_m(\mathbf{x})$, 最小化误差 $J_m = \sum_{n=1}^N w_n^{(m)} I(y_m(\mathbf{x}_n) \neq t_n)$,

其中 $I(y_m(\mathbf{x}_n) \neq t_n)$ 为指示函数, 当 $y_m(\mathbf{x}_n) \neq t_n$ 时等于1, 否则为0

误差越小, 权重越大, 重视可靠分类器

- 分类器权重: $\epsilon_m = \frac{\sum_{n=1}^N w_n^{(m)} I(y_m(\mathbf{x}_n) \neq t_n)}{\sum_{n=1}^N w_n^{(m)}}, \alpha_m = \ln \left\{ \frac{1-\epsilon_m}{\epsilon_m} \right\}$

误差越大, 权重越大, 重视困难样本


- 更新样本权重: $w_n^{(m+1)} = w_n^{(m)} \exp\{\alpha_m I(y_m(\mathbf{x}_n) \neq t_n)\}$

输出最终分类器: $Y_M(\mathbf{x}) = \text{sign}(\sum_{m=1}^M \alpha_m y_m(\mathbf{x}))$




AdaBoost算法


弱分类器1



AdaBoost算法




弱分类器2




AdaBoost算法


权重增加



弱分类器3



最终分类器
是弱分类器的组合




AdaBoost算法

➤ AdaBoost应用实例

给定训练样本：

X1	2	2.1	4.5	4	3.5	5	5	6	8	8
X2	3	2	6	5	1	7	3	5.5	6	2
t	1	1	1	-1	-1	1	-1	1	-1	-1



假设备选的弱分类器如下：

$$y_1(x_1, x_2) = \begin{cases} 1, & x_1 < 3 \\ -1, & x_1 > 3 \end{cases}$$

$$y_2(x_1, x_2) = \begin{cases} 1, & x_1 < 7 \\ -1, & x_1 > 7 \end{cases}$$

$$y_3(x_1, x_2) = \begin{cases} -1, & x_2 < 5.1 \\ 1, & x_2 > 5.1 \end{cases}$$

AdaBoost算法

➤弱分类器 $t = 1$

X1	2	2.1	4.5	4	3.5	5	5	6	8	8
X2	3	2	6	5	1	7	3	5.5	6	2
t	1	1	1	-1	-1	1	-1	1	-1	-1
w	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1

初始化训练数据权重分布：

$$w_n = \frac{1}{N} = 0.1, (N = 10, n = 1, \dots, N)$$

误差最小的阈值取在X1方向2.1与3.5之间，则第一个弱分类器应选：

$$y_1(x_1, x_2) = \begin{cases} 1, & x_1 < 3 \\ -1, & x_1 > 3 \end{cases}$$

AdaBoost算法

➤ 弱分类器 $t = 1$

给定训练样本（10个数据初始化权重皆为0.1）：


X1	2	2.1	4.5	4	3.5	5	5	6	8	8
X2	3	2	6	5	1	7	3	5.5	6	2
t	1	1	1	-1	-1	1	-1	1	-1	-1
w	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
y_1	1	1	-1	-1	-1	-1	-1	-1	-1	-1

则样本3、6、8为错分样本，错误率为：

$$\epsilon_1 = \frac{\sum_{n=1}^N w_n^{(m)} I(y_m(\mathbf{x}_n) \neq t_n)}{\sum_{n=1}^N w_n} = 0.3$$

由错误率计算得弱分类器1的权重：

$$\alpha_1 = \ln \frac{1 - \epsilon_1}{\epsilon_1} = 0.847$$



AdaBoost算法

➤弱分类器 $t=2$

更新训练样本权重： $w_n^{(2)} = w_n^{(1)} \exp\{\alpha_1 I(y_1(x_n) \neq t_n)\}$

X1	2	2.1	4.5	4	3.5	5	5	6	8	8
X2	3	2	6	5	1	7	3	5.5	6	2
t	1	1	1	-1	-1	1	-1	1	-1	-1
w	0.1	0.1	0.233	0.1	0.1	0.233	0.1	0.233	0.1	0.1

误差最小的阈值取在 x_1 方向6与8之间，则第二个弱分类器应选：

$$y_2(x_1, x_2) = \begin{cases} 1, x_1 < 7 \\ -1, x_1 > 7 \end{cases}$$

AdaBoost算法

➤弱分类器 $t=2$

分类结果：

$$y_2(x_1, x_2) = \begin{cases} 1, x_1 < 7 \\ -1, x_1 > 7 \end{cases}$$


X1	2	2.1	4.5	4	3.5	5	5	6	8	8
X2	3	2	6	5	1	7	3	5.5	6	2
t	1	1	1	-1	-1	1	-1	1	-1	-1
w	0.1	0.1	0.233	0.1	0.1	0.233	0.1	0.233	0.1	0.1
y_2	1	1	1	1	1	1	1	1	-1	-1

则样本4、5、7为错分样本，错误率为：

$$\epsilon_2 = \frac{\sum_{n=1}^N w_n^{(m)} I(y_m(x_n) \neq t_n)}{\sum_{n=1}^N w_n} = 0.214$$

由错误率计算得弱分类器2的权重：

$$\alpha_2 = \ln \frac{1 - \epsilon_2}{\epsilon_2} = 1.301$$



AdaBoost算法

➤弱分类器 $t=3$

更新训练样本权重： $w_n^{(3)} = w_n^{(2)} \exp\{\alpha_2 I(y_2(x_n) \neq t_n)\}$

X1	2	2.1	4.5	4	3.5	5	5	6	8	8
X2	3	2	6	5	1	7	3	5.5	6	2
t	1	1	1	-1	-1	1	-1	1	-1	-1
w	0.1	0.1	0.233	0.367	0.367	0.233	0.367	0.233	0.1	0.1

误差最小的阈值取在X2方向5与5.5之间，则第三个弱分类器应选：

$$y_3(x_1, x_2) = \begin{cases} -1, & x_2 < 5.1 \\ 1, & x_2 > 5.1 \end{cases}$$

AdaBoost算法

➤弱分类器 $t=3$

$$y_3(x_1, x_2) = \begin{cases} -1, & x_2 < 5.1 \\ 1, & x_2 > 5.1 \end{cases}$$

分类结果：


X1	2	2.1	4.5	4	3.5	5	5	6	8	8
X2	3	2	6	5	1	7	3	5.5	6	2
t	1	1	1	-1	-1	1	-1	1	-1	-1
w	0.1	0.1	0.233	0.367	0.367	0.233	0.367	0.233	0.1	0.1
y_3	-1	-1	1	-1	-1	1	-1	1	1	-1

则样本1、2、9为错分样本，错误率为：

$$\epsilon_3 = \frac{\sum_{n=1}^N w_n^{(m)} I(y_m(x_n) \neq t_n)}{\sum_{n=1}^N w_n} = 0.136$$

由错误率计算得弱分类器3的权重：

$$\alpha_3 = \ln \frac{1 - \epsilon_3}{\epsilon_3} = 1.849$$




AdaBoost算法

➤3个弱分类器合并成一个强分类器：

$$\text{sign}(Y(x_1, x_2)) = \text{sign}(0.847y_1(x_1, x_2) + 1.301y_2(x_1, x_2) + 1.849y_3(x_1, x_2))$$

X1	2	2.1	4.5	4	3.5	5	5	6	8	8
X2	3	2	6	5	1	7	3	5.5	6	2
<i>t</i>	1	1	1	-1	-1	1	-1	1	-1	-1
<i>sign</i> (Y)	1	1	1	-1	-1	1	-1	1	-1	-1



在训练集上有0个误差点，训练结束

多个简单的线性分类器实现二维空间的非线性分类功能。

AdaBoost算法

- AdaBoost习题

给定训练样本：

X	0	1	2	3	4	5	6	7	8	9
t	1	1	1	-1	-1	-1	1	1	1	-1

可选的弱分类器如下：

$$y(x) = \begin{cases} 1, x < 2.5 \\ -1, x > 2.5 \end{cases} \quad y(x) = \begin{cases} 1, x < 8.5 \\ -1, x > 8.5 \end{cases} \quad y(x) = \begin{cases} -1, x < 5.5 \\ 1, x > 5.5 \end{cases}$$

试利用AdaBoost算法求取强分类器判别函数。

AdaBoost算法

➤弱分类器 $t = 1$

给定训练样本（10个数据初始化权重皆为0.1）：

X	0	1	2	3	4	5	6	7	8	9
t	1	1	1	-1	-1	-1	1	1	1	-1
w	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1

误差最小的阈值取在2与3或者8与9之间，任取其一，

则第一个弱分类器为：

$$y_1(x) = \begin{cases} 1, x < 2.5 \\ -1, x > 2.5 \end{cases}$$

AdaBoost算法

➤ 弱分类器 $t = 1$

分类结果：

$$y_1(x) = \begin{cases} 1, x < 2.5 \\ -1, x > 2.5 \end{cases}$$

X	0	1	2	3	4	5	6	7	8	9
t	1	1	1	-1	-1	-1	1	1	1	-1
w	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1	0.1
y_1	1	1	1	-1	-1	-1	-1	-1	-1	-1

则样本6、7、8为错分样本，错误率为：

$$\epsilon_1 = \frac{P(y_1(x_i) \neq t_i)}{\sum_{n=1}^N w_n} = 0.3$$

由错误率计算得弱分类器1的权重： $\alpha_1 = \ln \frac{1-\epsilon_1}{\epsilon_1} = 0.8473$

AdaBoost算法

➤弱分类器 $t = 2$

更新训练样本权重: $w_n^{(2)} = w_n^{(1)} \exp\{\alpha_1 I(y_1(\mathbf{x}_n) \neq t_n)\}$

x	0	1	2	3	4	5	6	7	8	9
t	1	1	1	-1	-1	-1	1	1	1	-1
w	0.1	0.1	0.1	0.1	0.1	0.1	0.23 3	0.23 3	0.23 3	0.1

误差最小的阈值取在8与9之间，则第二个弱分类器为：

$$y_2(\mathbf{x}) = \begin{cases} 1, x < 8.5 \\ -1, x > 8.5 \end{cases}$$

AdaBoost算法

➤ 弱分类器 $t = 2$

分类结果:

$$y_2(x) = \begin{cases} 1, x < 8.5 \\ -1, x > 8.5 \end{cases}$$

X	0	1	2	3	4	5	6	7	8	9
t	1	1	1	-1	-1	-1	1	1	1	-1
w	0.1	0.1	0.1	0.1	0.1	0.1	0.23 3	0.23 3	0.23 3	0.1
y ₂	1	1	1	1	1	1	1	1	1	-1

则样本3、4、5为错分样本，错误率为：

$$\epsilon_2 = \frac{P(y_2(x_i) \neq t_i)}{\sum_{n=1}^N w_n} = 0.2144$$

由错误率计算得弱分类器1的权重： $\alpha_2 = \ln \frac{1-\epsilon_2}{\epsilon_2} = 1.2986$



AdaBoost算法

➤弱分类器 $t = 3$

更新训练样本权重: $w_n^{(3)} = w_n^{(2)} \exp\{\alpha_2 I(y_2(\mathbf{x}_n) \neq t_n)\}$

x	0	1	2	3	4	5	6	7	8	9
t	1	1	1	-1	-1	-1	1	1	1	-1
w	0.1	0.1	0.1	0.36 6	0.36 6	0.36 6	0.23 3	0.23 3	0.23 3	0.1

误差最小的阈值取在5与6之间，则第三个弱分类器为：

$$y_3(\mathbf{x}) = \begin{cases} -1, x < 5.5 \\ 1, x > 5.5 \end{cases}$$

AdaBoost算法

➤弱分类器 $t = 3$

分类结果:

$$y_3(x) = \begin{cases} -1, x < 5.5 \\ 1, x > 5.5 \end{cases}$$

X	0	1	2	3	4	5	6	7	8	9
t	1	1	1	-1	-1	-1	1	1	1	-1
w	0.1	0.1	0.1	0.36 6	0.36 6	0.36 6	0.23 3	0.23 3	0.23 3	0.1
y_3	-1	-1	-1	-1	-1	-1	1	1	1	1

则样本0、1、2、9为错分样本，错误率为：

$$\epsilon_3 = \frac{P(y_3(x_i) \neq t_i)}{\sum_{n=1}^N w_n} = 0.1821$$

由错误率计算得弱分类器1的权重： $\alpha_3 = \ln \frac{1-\epsilon_3}{\epsilon_3} = 1.5022$

AdaBoost算法

➤ 3个弱分类器合并成一个强分类器：

$$\text{sign}(Y(x)) = \text{sign}(0.8473y_1(x) + 1.2986y_2(x) + 1.5022y_3(x))$$

X	0	1	2	3	4	5	6	7	8	9
t	1	1	1	-1	-1	-1	1	1	1	-1
$\text{sign}(Y)$	1	1	1	-1	-1	-1	1	1	1	-1

在训练集上有0个误差点，训练结束